



Aussa Tris Rahmatullah

Education Background



2010-2014
Bachelor Degree
Electrical Engineering



2018-2019 Master DegreeData Science and Analytics



Aussa Tris Rahmatullah

https://id.linkedin.com/in/aussa-tris-rahmatullah



Data Visualization

Basic Plots





Objektif



Memahami apa **urgensi proses** memvisualisasikan data dan apa **prinsip yang harus dipegang** dalam melakukan visualisasi data, dan mampu membuat dan memilih jenis chart sesuai dengan kegunaan masing masing.



Expected Output



- Memahami apa urgensi proses memvisualisasikan data dan apa prinsip yang harus dipegang dalam melakukan visualisasi data
- 2. Memahami **perbedaan kegunaan** masing masing jenis chart dan tabel dalam merepresentasikan data
- Mampu melakukan operasi pembuatan chart dan tabel untuk menggambarkan suatu perbandingan data
- 4. Mampu melakukan operasi pembuatan chart dan tabel untuk menggambarkan **hubungan dalam data**
- 5. Mampu melakukan operasi pembuatan chart dan tabel untuk menggambarkan **distribusi pada data**
- 6. Mampu melakukan operasi pembuatan chart dan tabel untuk menggambarkan **komposisi pada data**



Hands On Required

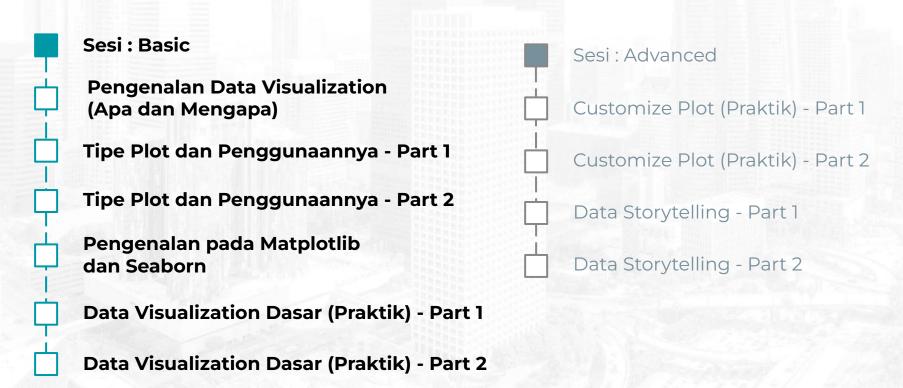
Hands - On: 1. Basic Plot

Klik disini untuk mengakses folder Hands On

Outline Pembelajaran



Topik Data Visualization



Outline Pembelajaran



Topik Data Visualization

	Sesi : Basic		Sesi : Advanced
	Pengenalan Data Visualization (Apa dan Mengapa)	<u></u>	Customize Plot (Praktik) - Part 1
þ	Tipe Plot dan Penggunaannya - Part 1		Customize Plot (Praktik) - Part 2
į.	Tipe Plot dan Penggunaannya - Part 2		Data Storytelling - Part 1
į.	Pengenalan pada Matplotlib dan Seaborn	-	Data Storytelling - Part 2
į.	Data Visualization Dasar (Praktik) - Part 1		
Ġ	Data Visualization Dasar (Praktik) - Part 2		



Pengenalan Data Visualization





Jumlah kasus baru COVID-19 yang terkonfirmasi per minggunya di Indonesia

Sumber: WHO



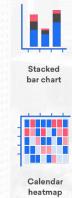
sparkline

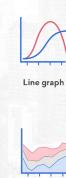
Apa itu Data Visualization?

"Teknik yang digunakan untuk
mengkomunikasikan data atau informasi
dengan mengkodekannya sebagai objek
visual (titik, garis atau batang) yang
terdapat dalam grafik."



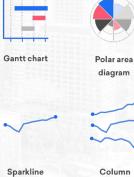
Scatter plot





Stacked

area chart



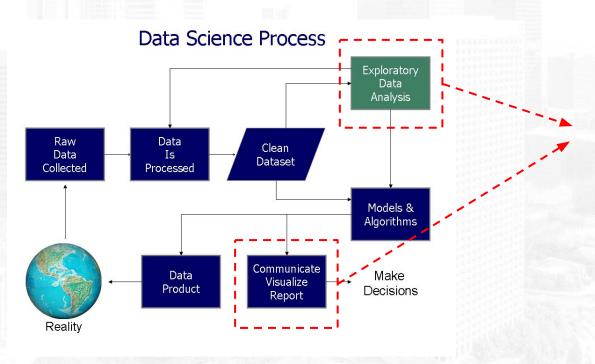


"An ideal visualization should not only communicate clearly, but stimulate viewer engagement and attention"

<u>Fernanda Viegas</u> and <u>Martin Wattenberg</u> (April 19, 2011). "<u>How To Make Data Look Sexy</u>". CNN.com



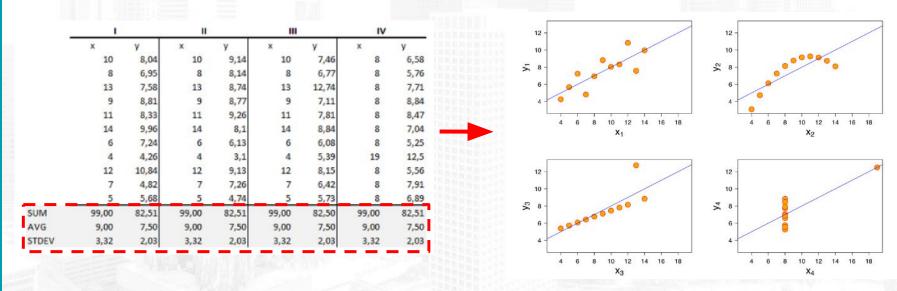
Mengapa Data Visualization?



Data Visualization dibutuhkan untuk melakukan dua tahap ini



Mengapa Data Visualization?



Anscombe's Quartet

Terdapat 4 dataset yang mempunyai statistik deskriptif yang sama, namun pola visualisasi yang jauh berbeda

Outline Pembelajaran



Topik Data Visualization

	Sesi : Basic		Sesi : Advanced
	Pengenalan Data Visualization (Apa dan Mengapa)	<u></u>	Customize Plot (Praktik) - Part 1
P	Tipe Plot dan Penggunaannya - Part 1	<u></u>	Customize Plot (Praktik) - Part 2
į.	Tipe Plot dan Penggunaannya - Part 2		Data Storytelling - Part 1
4	Pengenalan pada Matplotlib dan Seaborn	<u> </u>	Data Storytelling - Part 2
ψ̈́.	Data Visualization Dasar (Praktik) - Part 1		
$\dot{\Box}$	Data Visualization Dasar (Praktik) - Part 2		

Outline Pembelajaran



Topik Data Visualization

	Sesi : Basic		Sesi : Advanced
2	Pengenalan Data Visualization (Apa dan Mengapa)	<u></u>	Customize Plot (Praktik) - Part 1
	Tipe Plot dan Penggunaannya - Part 1		Customize Plot (Praktik) - Part 2
į.	Tipe Plot dan Penggunaannya - Part 2		Data Storytelling - Part 1
†	Pengenalan pada Matplotlib dan Seaborn	<u></u>	Data Storytelling - Part 2
į.	Data Visualization Dasar (Praktik) - Part 1		
Ġ	Data Visualization Dasar (Praktik) - Part 2		



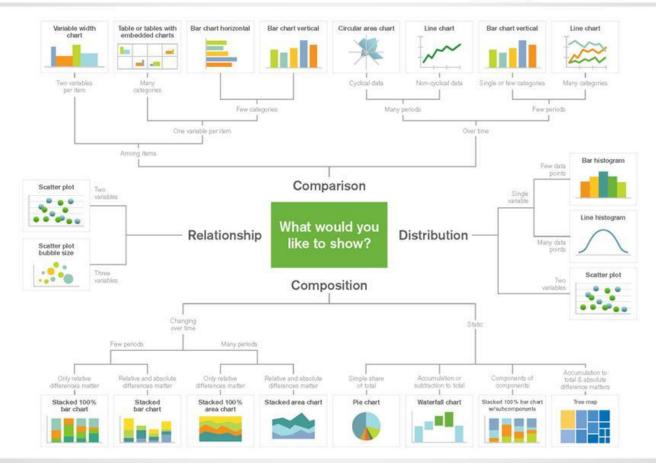
Tipe Plot dan Penggunaannya

Part 1



Penggunaan

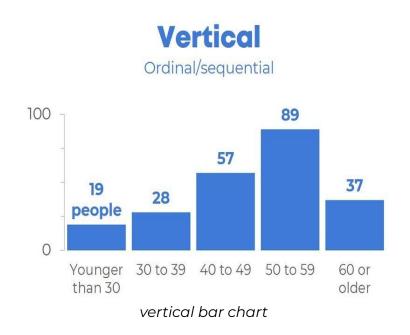
- Perbandingan
- Distribusi
- Hubungan
- Komposisi





Perbandingan antar Item

Digunakan untuk membandingkan item yang **lebih sedikit** (kurang dari 6 item)



Dapat dilihat dari grafik di samping bahwa jumlah orang terbanyak ada di rentang usia 50 sampai 59 dengan jumlah 89 orang

Sedangkan untuk jumlah orang terendah ada di rentang usia kurang dari 30 tahun dengan jumlah 19 orang



Perbandingan antar Item

Dapat dilihat dari grafik di samping bahwa jumlah orang terbanyak ada di sektor Government dengan jumlah 89 orang

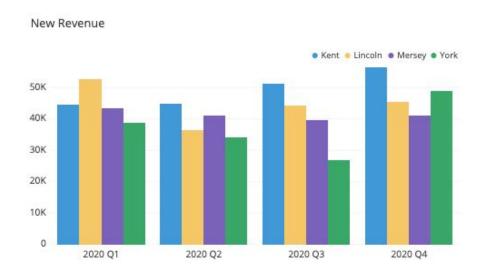
Sedangkan untuk jumlah orang terendah ada di sektor Other dengan jumlah 19 orang Digunakan untuk membandingkan item yang **cukup banyak** (lebih dari 6 item)





Perbandingan antar Item terhadap waktu

Digunakan untuk membandingkan item terhadap waktu yang **lebih sedikit** (kurang dari 10 periode waktu)



Grafik di samping menunjukan new revenue dari berbagai Kota di US dari tahun 2020 kuartal 1 hingga kuartal 4

Pada Kuartal 1, revenue tertinggi ada di kota Lincoln sedangkan pada kuartal 4, kota kent merupakan kota dengan revenue terbesar

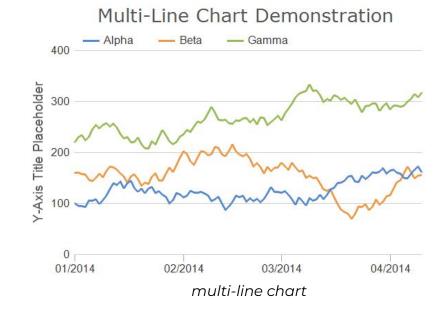
multi-bar chart



Perbandingan antar Item terhadap waktu

Grafik di samping menunjukan bahwa Gamma mempunyai nilai yang tertinggi dari bulan Januari 2014 hingga April 2014

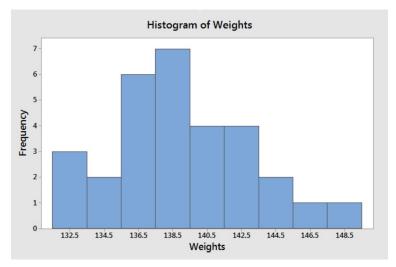
Sedangkan untuk Beta sempat menjadi tertinggi kedua, namun pada pertengahan bulan Maret 2014 turun menjadi urutan ke 3, dan sempat naik sedikit sebentar pada awal April, 2014 Digunakan untuk membandingkan item terhadap waktu yang **cukup banyak** (lebih dari 10 periode waktu)





Distribusi suatu Item

Plot distribusi konvensional yang bergantung pada jumlah *bin* (banyaknya kotak yang menggambarkan *range* data)



histogram

Grafik di samping menunjukan distribusi dari Weights, dimana untuk nilai tertinggi terdapat pada rentang 137-139 dengan total 7 data.

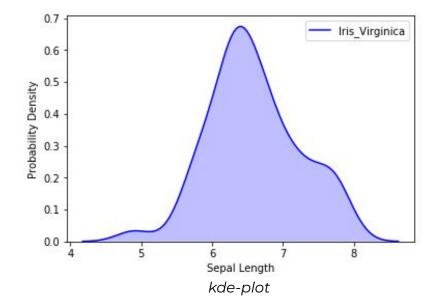
Sebaliknya, nilai terendah terdapat pada rentang 145-149 dengan total 2 data.



Distribusi suatu Item

Grafik di samping menunjukan distribusi data Sepal Length dari bunga Iris Virginica yang telah ditransformasi menggunakan teknik kernel-smoothing.

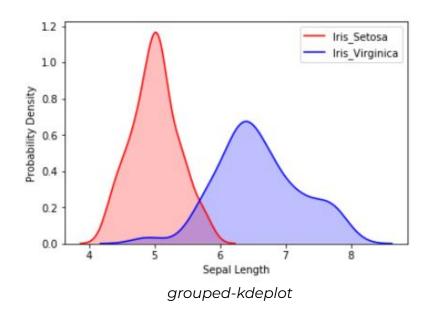
Dapat dilihat bahwa distribusi terbanyak ada di range panjang 6-7 dengan nilai *probability density* 0.7. Menggunakan <u>kernel-smoothing</u>, kde-plot lebih baik dalam menentukan bentuk distribusi karena tidak terpengaruh oleh jumlah *bin* yang digunakan





Distribusi antar Item

Atau kita juga dapat menggunakan **grouped-kdeplot** untuk melihat distribusi antar item



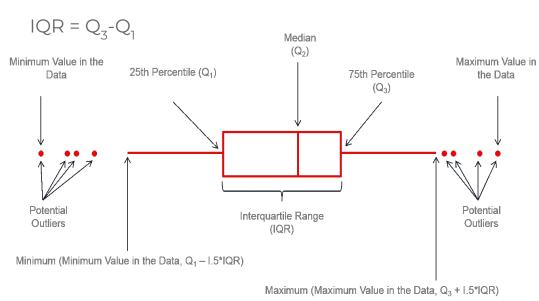
Grafik di samping menunjukan distribusi data Sepal Length dari bunga Iris Virginica dan bunga Iris Setosa yang telah ditransformasi menggunakan teknik kernel-smoothing.

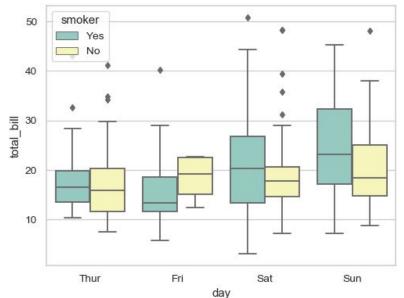
Dapat dilihat bahwa Sepal Length Iris Virginica mayoritas lebih panjang dari Sepal Length Iris Setosa.



Distribusi antar Item

Boxplot memberikan deskripsi data yang cukup detail, seperti median, kuantil ke 25 dan 75, serta outlier





grouped-boxplot

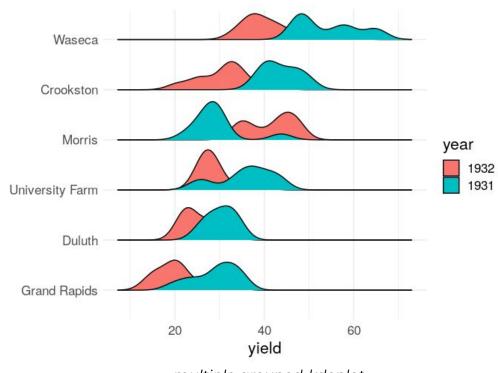
cara membaca boxplot



Distribusi antar Item

Grafik di samping menunjukan distribusi *yield* dari berbagai kota pada tahun 1931 dan 1932.

Dapat dilihat bahwa *yield* terbesar berada di kota Waseca. Sebagian besar yield pada 1932 lebih kecil dibanding *yield* pada tahun sebelumnya, kecuali untuk kota Morris.



multiple grouped-kdeplot

Outline Pembelajaran



Topik Data Visualization

	Sesi : Basic		Sesi : Advanced
	Pengenalan Data Visualization (Apa dan Mengapa)	<u></u>	Customize Plot (Praktik) - Part 1
	Tipe Plot dan Penggunaannya - Part 1		Customize Plot (Praktik) - Part 2
ψ̈́	Tipe Plot dan Penggunaannya - Part 2		Data Storytelling - Part 1
$\dot{\Box}$	Pengenalan pada Matplotlib dan Seaborn		Data Storytelling - Part 2
ψ̈́.	Data Visualization Dasar (Praktik) - Part 1		
Ġ	Data Visualization Dasar (Praktik) - Part 2		

Outline Pembelajaran



Topik Data Visualization

	Sesi : Basic		Sesi : Advanced
	Pengenalan Data Visualization (Apa dan Mengapa)	<u></u>	Customize Plot (Praktik) - Part 1
	Tipe Plot dan Penggunaannya - Part 1	4	Customize Plot (Praktik) - Part 2
	Tipe Plot dan Penggunaannya - Part 2		Data Storytelling - Part 1
†	Pengenalan pada Matplotlib dan Seaborn	-	Data Storytelling - Part 2
Image: Control of the	Data Visualization Dasar (Praktik) - Part 1		
	Data Visualization Dasar (Praktik) - Part 2		



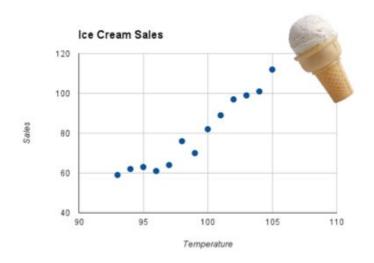
Tipe **Plot** dan **Penggunaannya**

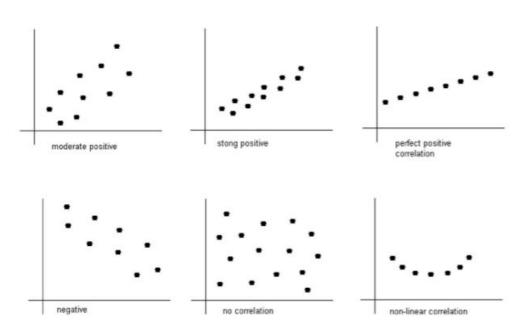
Part 2



Hubungan antar Item

Dengan menggunakan scatter plot kita dapat melihat korelasi atau hubungan antar item





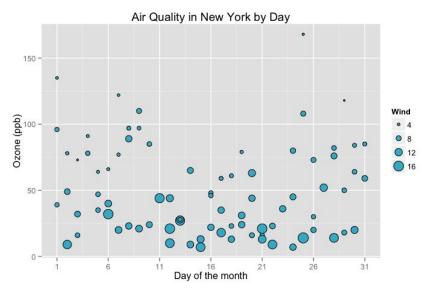
scatter plot

correlation in scatter plot



Hubungan antar beberapa Item

Memainkan **ukuran** dari data point untuk mencari hubungan terhadap item lain



bubble scatter plot

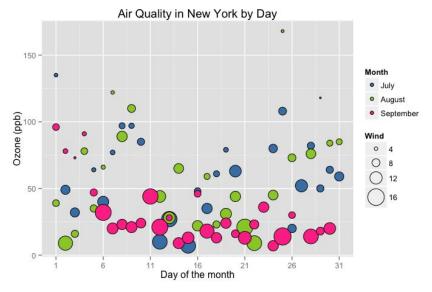
Grafik di samping menunjukan persebaran tingkat *Ozone* dari harian dalam satu bulan dibandingkan dengan kekuatan anginnya, dimana semakin besar *point* maka semakin besar kekuatan angin.

Dilihat dari grafik di samping, semakin rendah tingkat Ozone maka semakin tinggi kekuatan angin.



Hubungan antar beberapa Item

Sama dengan grafik diatas, namun pada grafik ini ditambahkan satu fitur lagi yaitu fitur bulan yang direpresentasikan dengan warna. Memainkan **warna** dari data point untuk mencari hubungan terhadap item lain

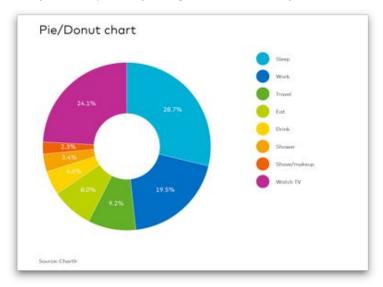


bubble scatter plot



Komposisi antar Item

Cocok digunakan untuk menjelaskan kontribusi dari setiap item, namun banyak *expert* yang tidak menyarankan



Grafik di samping menunjukan aktivitas terbanyak adalah sleep dengan nilai 28.7%, namun *pie chart* ini sebaiknya digunakan untuk data yang tidak lebih dari 5.

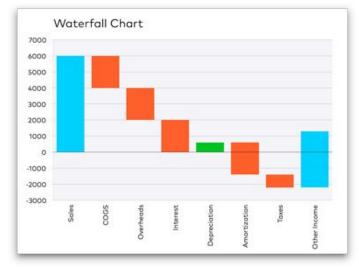
pie chart



Komposisi antar Item

Grafik di samping menunjukan bagaimana suatu nilai awal terpengaruh dari rangkaian nilai positif ataupun negatif.

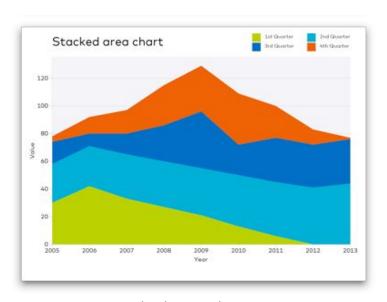
Nilai awal dari sales yang bernilai 6000 mengalami pengurangan dari biaya COGS, overheads, interest, amortisation, dan taxes. Dan, terdapat penambahan nilai dari depreciation dan other income. Cocok digunakan untuk melihat perubahan komposisi terhadap suatu event





Komposisi antar Item terhadap waktu

Grafik ini cocok digunakan untuk melihat komposisi dari beberapa item terhadap waktu, tergantung preferensi masing-masing



stacked area chart

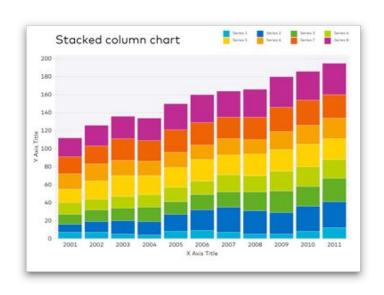
Grafik di samping menunjukan value dari tahun 2005-2013 yang dibagi menjadi 4 quarter.

Dapat terlihat bahwa pada awal tahun 2005 di quarter pertama memiliki value terbesar. Sedangkan, pada akhir tahun 2013, value dari quarter 1 adalah 0; value terbesar ada pada quarter 2.



Komposisi antar Item terhadap waktu

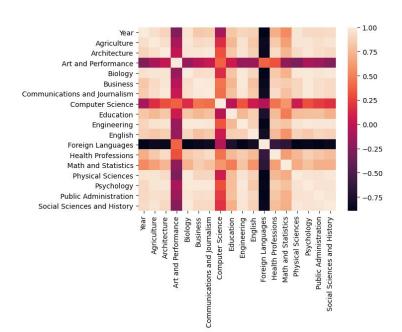
Selain grafik diatas, grafik ini cocok digunakan untuk melihat komposisi dari beberapa item terhadap waktu, namun menggunakan column chart.



stacked column chart



Jenis chart lainnya



Biasa digunakan untuk melihat **korelasi** atau **hubungan** antara variabel dengan variabel lainnya.

Terlihat bahwa semakin gelap warna chart maka dua fitur tersebut semakin berkorelasi negatif. Sebaliknya, semakin terang warna chart maka semakin berkorelasi positif.

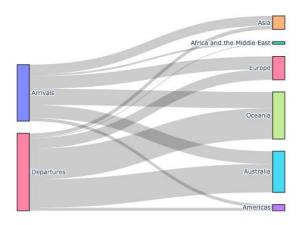
heatmap chart



Jenis chart lainnya

Bertujuan untuk menggambarkan **aliran** dari satu set nilai ke nilai yang lain.

Terlihat grafik mengenai migrasi populasi antara New Zealand dan benua lainnya. Sebagian besar kedatangan warga NZ berasal dari Europe, Oceania, dan Australia. Sedangkan, sebagian besar kepergian warga NZ menuju Oceania dan Australia. Population Migration between New Zealand and Other Continents



sankey chart

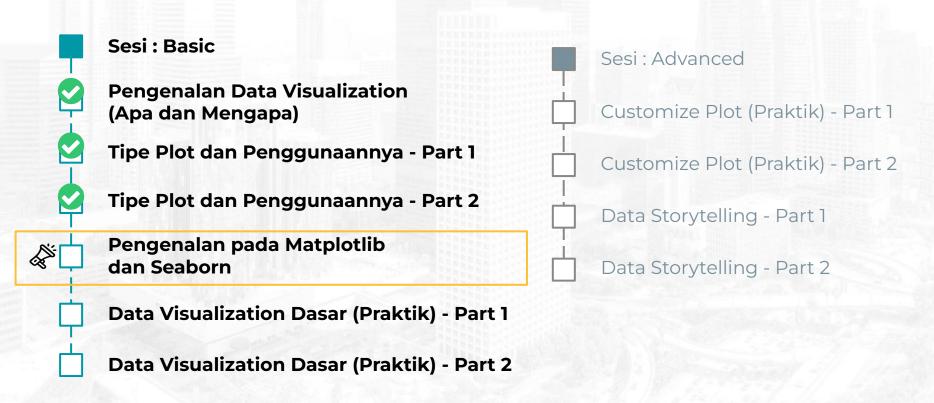


Topik Data Visualization

	Sesi : Basic		Sesi : Advanced
	Pengenalan Data Visualization (Apa dan Mengapa)	<u></u>	Customize Plot (Praktik) - Part 1
	Tipe Plot dan Penggunaannya - Part 1		Customize Plot (Praktik) - Part 2
	Tipe Plot dan Penggunaannya - Part 2		Data Storytelling - Part 1
†	Pengenalan pada Matplotlib dan Seaborn		Data Storytelling - Part 2
$\dot{\Box}$	Data Visualization Dasar (Praktik) - Part 1		
$\dot{\Box}$	Data Visualization Dasar (Praktik) - Part 2		



Topik Data Visualization





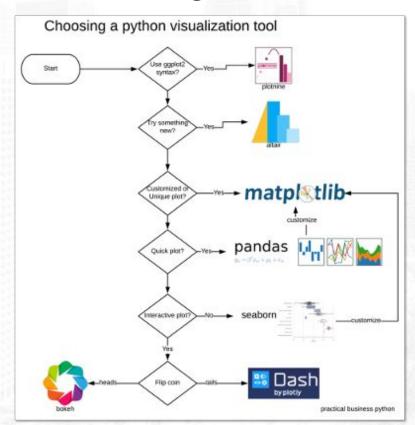
Matplotlib dan Seaborn



Data Visualization Library

Ini adalah beberapa *library* visualisasi di python yang sering digunakan

- Matplotlib: paling basic, punya tingkat kebebasan yang tinggi
- Pandas Visualization: interface yang sederhana, terintegrasi dengan matplotlib
- Seaborn: high-level interface, plot-plot statistika
- ggplot: berbasis dari ggplot2 bahasa pemrograman R
- Plotly / Bokeh: bisa membuat plot interaktif



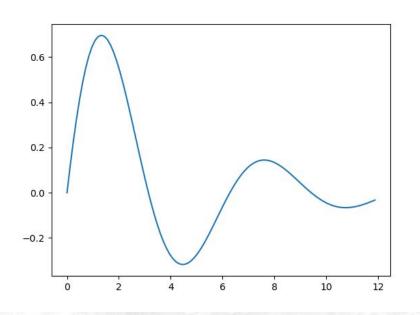


Matplotlib vs Seaborn

Fitur	Matplotlib	Seaborn				
Fungsionalitas	Dibuat untuk plot-plot dasar, berbasis fitur dan sintaks dari MATLAB	Terdapat banyak tipe plot, sangat baik terutama untuk statistika.				
Sintaks	Lebih kompleks dan panjang	Sederhana dan lebih mudah dipelajari				
Dataframe	Terintegrasi baik dengan Numpy dan Pandas	Sangat baik digunakan dengan Pandas				
Fleksibilitas	Sangat bebas (fleksibel)	Dalam beberapa kasus, cukup terbatas				
Penggunaan	Digunakan untuk membuat atau memodifikasi plot-plot dasar	Extended version dari Matplotlib, memiliki banyak tipe plot dan tema				



Matplotlib vs Seaborn



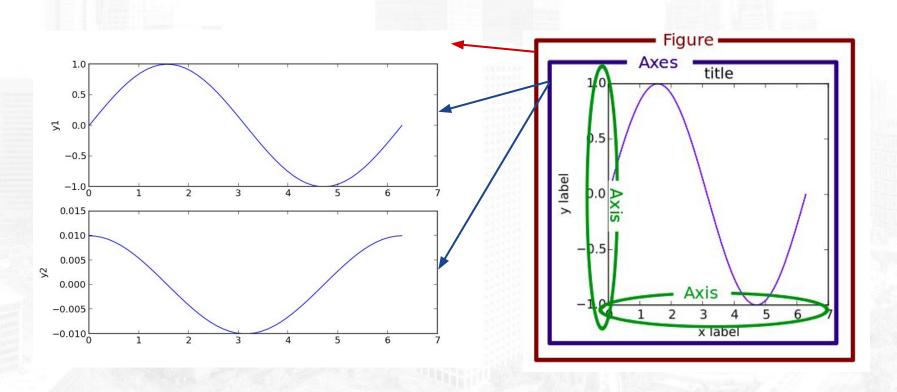
event 0.25 0.20 0.15 0.10 0.05 0.00 -0.05 -0.10 0.0 2.5 5.0 12.5 15.0 timepoint

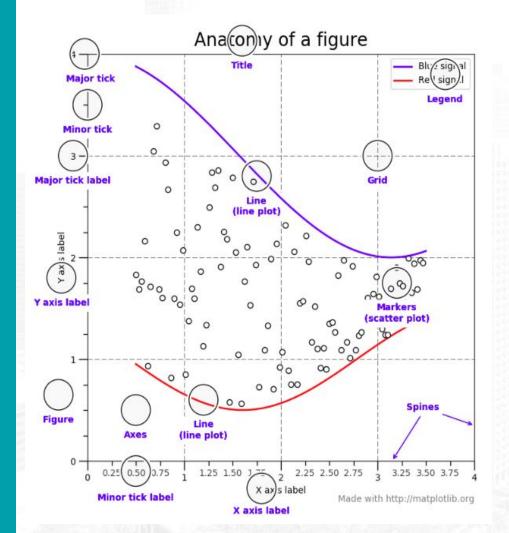
matplotlib

seaborn



Anatomi Matplotlib



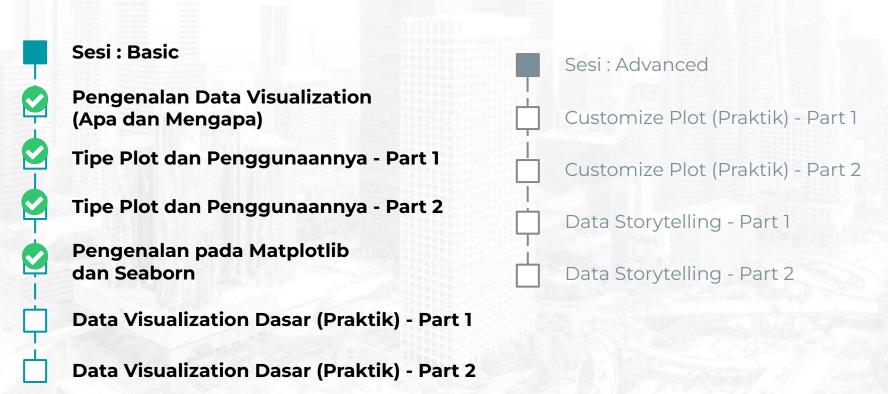




Matplotlib actually create this figure with python code!

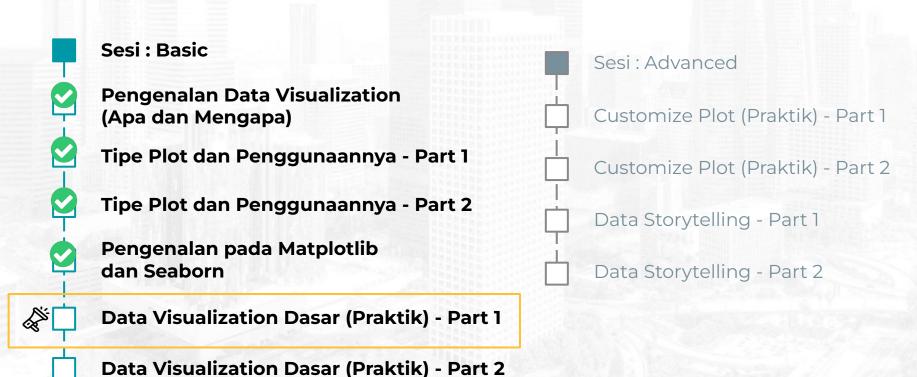


Topik Data Visualization





Topik Data Visualization





Visualisasi Dasar

Saatnya Praktik!

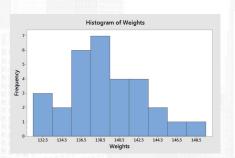


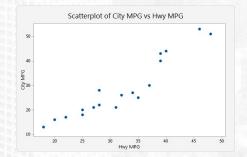
Saatnya Praktik!

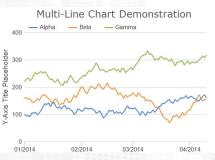
matpletlib Seaborn

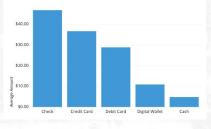












Membandingkan 3 *library* yang berbeda untuk berbagai tipe plot!



Dataset yang digunakan

Telco Customer Churn

Deskripsi:

Dataset ini menggambarkan perilaku dan profil pelanggan di perusahaan Telco yang digunakan guna menganalisis dan memprediksi retensi pelanggan.

• Data:

Setiap baris mewakili pelanggan, setiap kolom berisi atribut pelanggan.

Link download disini



Import Library

Pandas	Matplotlib	Seaborn			
import pandas as pd	import matplotlib.pyplot as plt	import seaborn as sns			
1 import pandas as pd 2 pdversion_ executed in 6ms, finished 20:16:57 2020-08	<pre>import matplotlib import matplotlib.pyplot as plt matplotlib. version</pre>	1 import seaborn as sns 2 snsversion_ executed in 455ms, finished 20:17:15 2020-08-08			
'0.23.4'	executed in 5ms, finished 20:17:00 2020-08-08	'0.9.0'			



Membaca (Read) Dataset

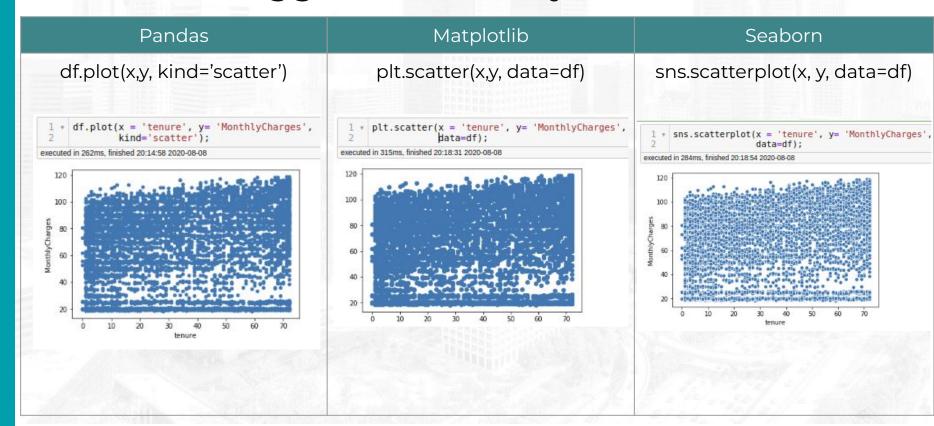
```
1 * # read csv
2   df = pd.read_csv('csv/telco_customer.csv')
3   df.head()
executed in 87ms, finished 20:14:05 2020-08-08
```

	customerID	gender	SeniorCitizen	Partner	Dependents	tenure	PhoneService	MultipleLines	InternetService	OnlineSecurity	 DeviceProtection	Tech
0	7590- VHVEG	Female	0	Yes	No	1	No	No phone service	DSL	No	 No	
1	5575- GNVDE	Male	0	No	No	34	Yes	No	DSL	Yes	 Yes	
2	3668- QPYBK	Male	0	No	No	2	Yes	No	DSL	Yes	 No	
3	7795- CFOCW	Male	0	No	No	45	No	No phone service	DSL	Yes	 Yes	
4	9237- HQITU	Female	0	No	No	2	Yes	No	Fiber optic	No	 No	

5 rows × 21 columns

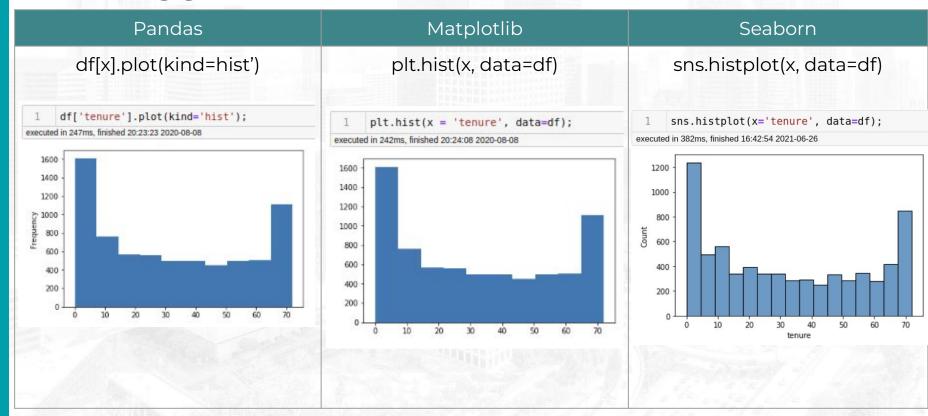


Scatter Plot: Mencari hubungan antara masa berlangganan dan biaya bulanan



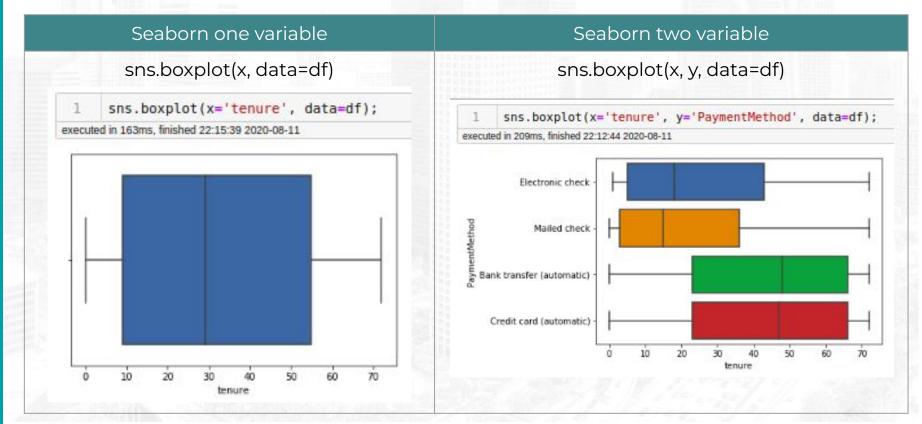


Histogram: Mencari distribusi dari masa berlangganan



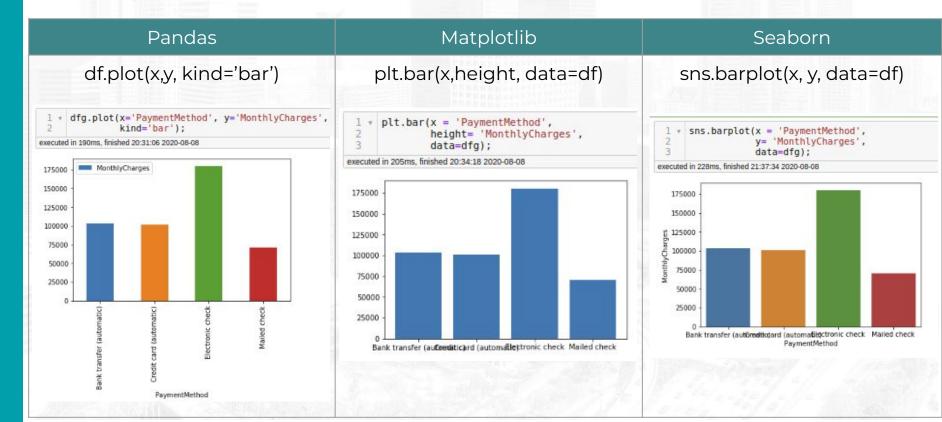


Boxplot: Mencari distribusi dari masa berlangganan



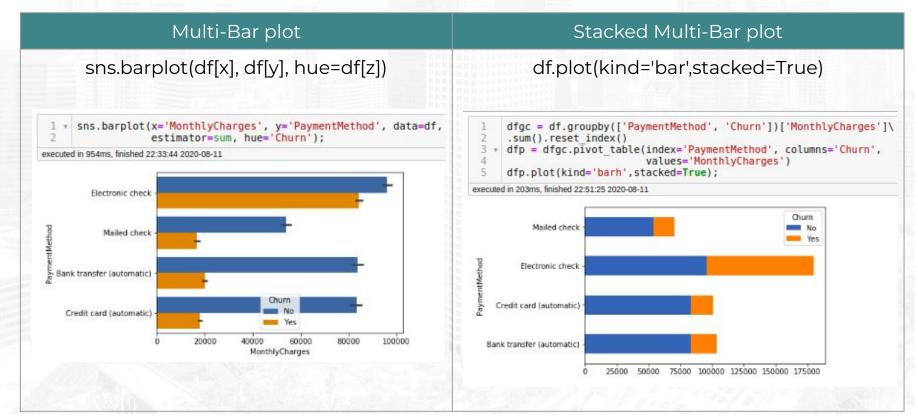


Barplot: Mencari rata-rata biaya bulanan untuk setiap metode pembayaran



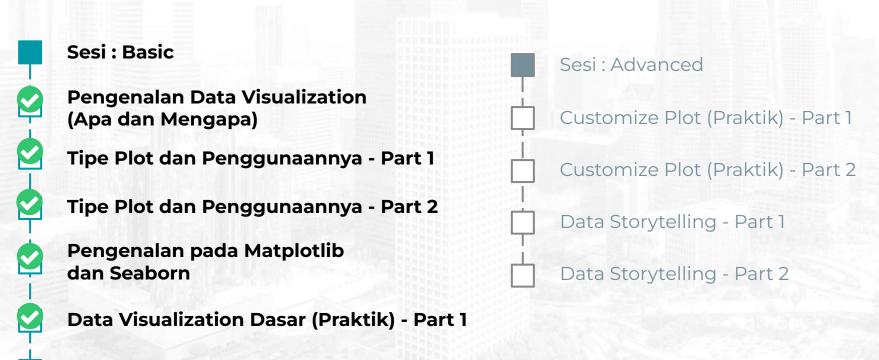


Multi-barplot: Mencari rata-rata biaya bulanan untuk setiap metode pembayaran dan berdasarkan *churn*





Topik Data Visualization



Data Visualization Dasar (Praktik) - Part 2



Topik Data Visualization



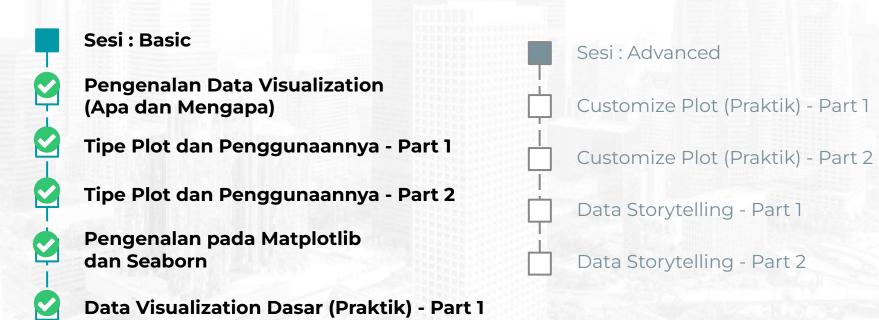




Data Visualization Dasar (Praktik) - Part 2



Topik Data Visualization



Data Visualization Dasar (Praktik) - Part 2







Aussa Tris Rahmatullah

https://id.linkedin.com/in/aussa-tris-rahmatullah

Aussa Rahmatullah

Data Scientist

Telco Company